

제목: AI 모델 학습 데이터 및 프롬프트 보안 도입 및 개선방안 보고

작성부서: 정보보호심사팀 | 작성일자: 2026-04-08
문서번호: HBC-16129 | 보안구분: 일반/기밀 대외비

[요약문 (Executive Summary)]

본 문서는 정보보호심사팀의 관리하에 진행되는 AI 모델 학습 데이터 및 프롬프트 보안 도입 및 개선방안 보고의 핵심 추진 과제를 정의하며, 실무 부서의 마일스톤 준수 및 정기 점검 사항을 포함하고 있습니다.

[상세 보고 내용]

- 가람정보보안의 차세대 LLM 제품 DocVault의 미세조정(Fine-Tuning) 학습 데이터 구성 및 프롬프트 설계 전략입니다. 모델 응답 안정성 확보 및 프롬프트 인젝션 차단 메커니즘을 상세 기술한 연구 기술서입니다.
- 우리는 DocVault 모델의 성능 강화를 위해 약 12만 건의 정제된 사내 데이터를 사용하며, 학습 파이프라인 보안을 적용합니다. 모델 구동 단계에서 탈옥(Jailbreak)을 차단하는 시스템 프롬프트 가이드는 1급 기밀로 유지되어야 합니다. 최근 내부 보안 실태 감사 결과에 따라 식별된 개선 사항을 신속하게 보완하고, 비즈니스 연속성을 극대화하기 위하여 관련 시스템의 점검이 시급히 요해됩니다.
- 연구 개발 파트: 윤예린 팀장, 소속 데이터관리팀, 연구용 서버 접속 IP 192.0.2.75, 이메일 yerin.yoon14@example.test 입니다. 모델 검증 결과 코드는 DSPROSENS86 이며 개발용 데이터 묶음 토큰은 SYNTH-EMPLOY-EE-Y153 로 명명하여 격리 보관합니다.
- 본 프롬프트 설계 정보 및 가중치 정보의 유출은 악의적인 공격에 취약점을 제공하게 되므로 열람 권한을 제한합니다. 협조해 주시는 모든 임직원 여러분께 감사드리며, 더욱 안정적이고 효율적인 업무 환경 조성을 위해 노력하겠습니다.

[향후 추진 마일스톤]

- Phase 1 (도입기): 지침 배포 및 부서별 사전 준비 (~ 2026-04-08)
- Phase 2 (안정기): 시스템 반영 및 실무 피드백 수렴 (도입 후 1개월)
- Phase 3 (고도화): 운영 효율성 평가 및 정기 정합성 감사 시행 (분기별)