

AI 모델 학습 데이터 및 프롬프트 보안 기술 백서 및 가이드라인

* 최근 수정: 양서윤 (v1.3)

* 카테고리: 사내 가이드

문서 개정이력 (Revision History)

| 개정 버전 | 개정 일자 | 개정자 | 개정 사유 및 요약 |

| :--- | :--- | :--- | :--- |

| v1.0 | 2026-01-15 | 장준서 | 최초 제정 및 초안 등록 |

| v1.3 | 2026-05-10 | 양서윤 | 최신 운영 규칙 및 상세 세부사항 현행화
|

1. 개요 및 취지

새벽솔루션의 차세대 LLM 제품 DocSearch Pro의 미세조정(Fine-Tuning) 학습 데이터 구성 및 프롬프트 설계 전략입니다. 모델 응답 안정성 확보 및 프롬프트 인젝션 차단 메커니즘을 상세 기술한 연구 기술서입니다.

2. 주요 운영 가이드라인

우리는 DocSearch Pro 모델의 성능 강화를 위해 약 12만 건의 정제된 사내 데이터를 사용하며, 학습 파이프라인 보안을 적용합니다. 모델 구동 단계에서 탈옥(Jailbreak)을 차단하는 시스템 프롬프트 가이드는 1급 기밀로 유지되어야 합니다. 본 정보는 사내 개인정보 보호 규정에 의거하여 1급 기밀로 분류되며, 허가되지 않은 무단 유출 및 복제를 일절 금지합니다.

3. 상세 항목 및 절차

연구 개발 파트: 노유진 부장, 소속 권한심사팀, 연구용 서버 접속 IP 203.0.113.32, 이메일 yujin.no56@example.test 입니다. 모델 검증 결과 코드는 DSPROSENS25이며 개발용 데이터 묶음 토큰은 SYNTH-EMPLOYEE-X213로 명명하여 격리 보관합니다.

4. 유의사항

본 프롬프트 설계 정보 및 가중치 정보의 유출은 악의적인 공격에 취약점을 제공하게 되므로
열람 권한을 제한합니다. 학습 진척도 대시보드 및 상세 평가는 연구 포털(dev.example.test)
에서 담당 승인자에 한해 조회할 수 있습니다. 열람 권한 보유자는 본 문서의
내용을 외부나 타 부서에 노출하지 않도록 보안 유지에 각별히 유의해 주십시오.

■ 관련 문서 바로가기 링크

- [사내 인프라 표준 운영 규정](wiki.example.test/infra-policy)
- [보안 가이드라인 및 취약점 조치 프로세스](wiki.example.test/security-guide)
- [업무 협업용 서식 자료실](wiki.example.test/templates)

*본 문서는 사내 지식 관리 시스템(Wiki)에서 공식 생성된 콘텐츠입니다. 무단 반출을
금합니다.*