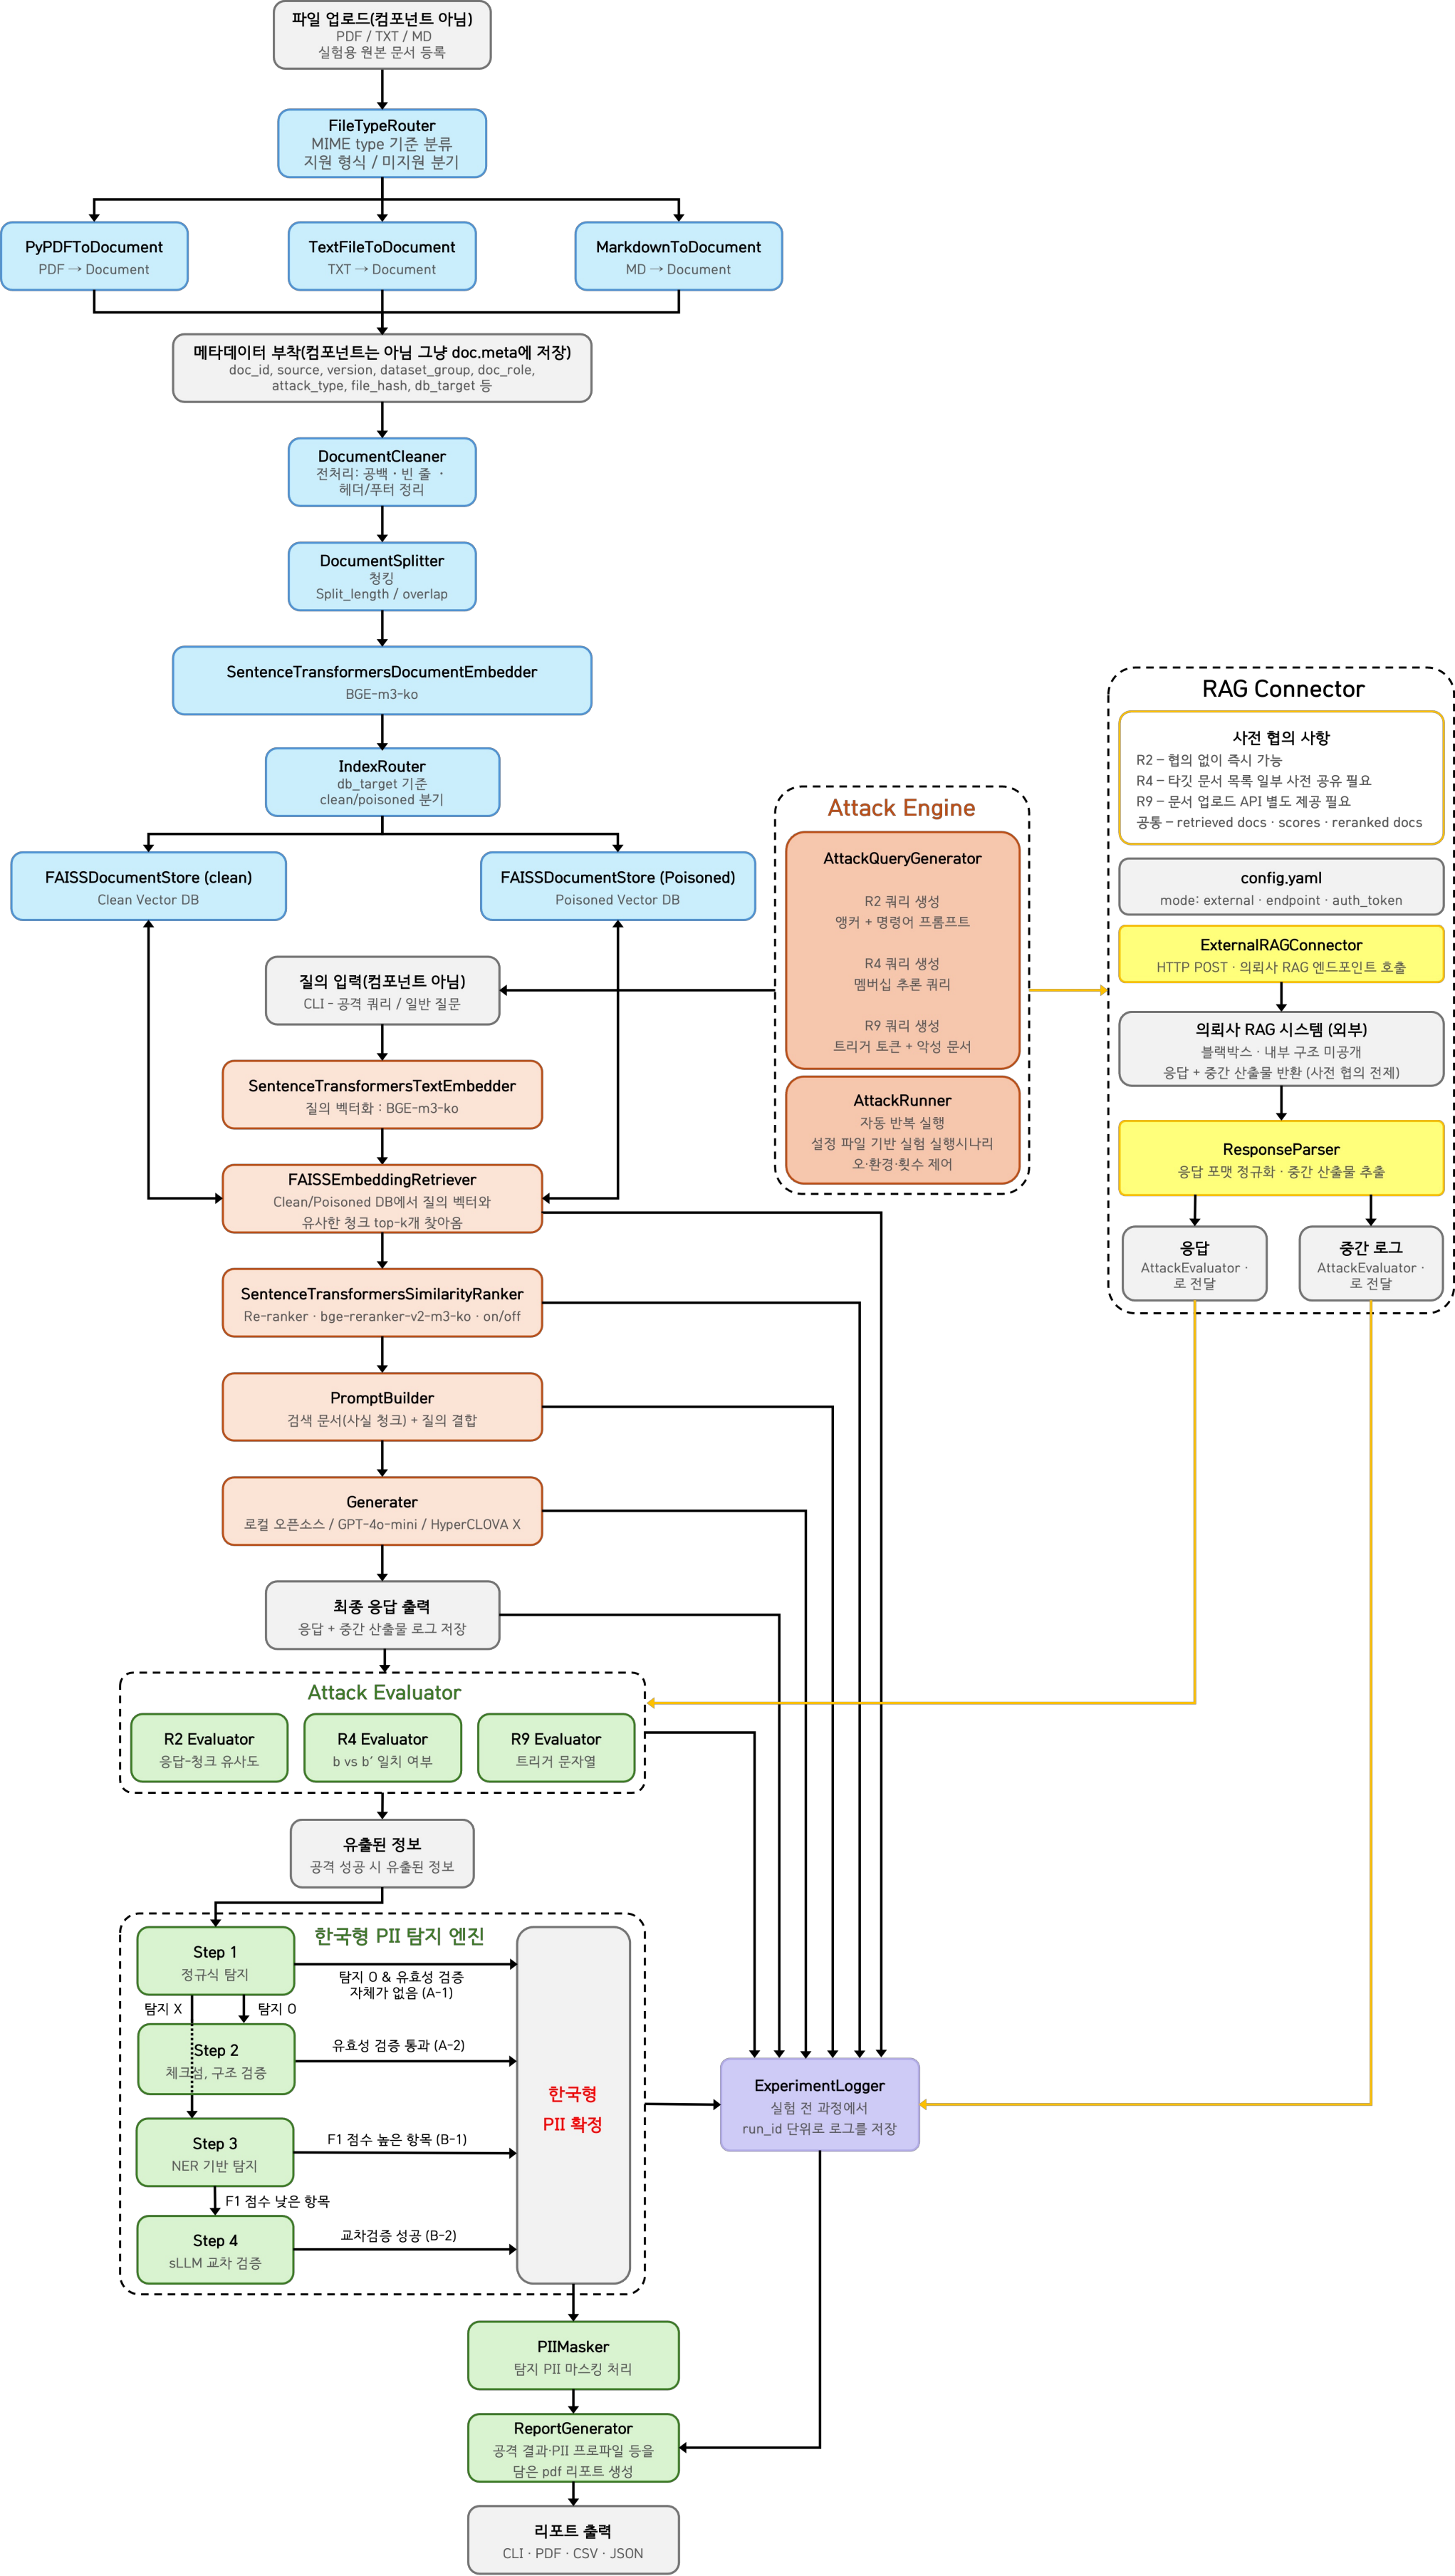
파일 업로드(컴포넌트 아님)
PDF / TXT / MD
실험용 원본 문서 등록
FileTypeRouter
MIME type 기준 분류
지원 형식 / 미지원 분기
PyPDFToDocument
PDF → Document
TextFileToDocument
TXT → Document
MarkdownToDocument
MD → Document
메타데이터 부착(컴포넌트는 아님 그냥 doc.meta에 저장)
doc_id, source, version, dataset_group, doc_role,
attack_type, file_hash, db_target 등
DocumentCleaner
전처리: 공백 · 빈 줄 ·
헤더/푸터 정리
DocumentSplitter
청킹
Split_length / overlap
SentenceTransformersDocumentEmbedder
BGE-m3-ko
IndexRouter
db_target 기준
clean/poisoned 분기
FAISSDocumentStore (clean)
Clean Vector DB
FAISSDocumentStore (Poisoned)
Poisoned Vector DB
Attack Engine
AttackQueryGenerator
R2 쿼리 생성
앵커 + 명령어 프롬프트
R4 쿼리 생성
멤버십 추론 쿼리
R9 쿼리 생성
트리거 토큰 + 악성 문서
AttackRunner
자동 반복 실행
설정 파일 기반 실험 실행시나리
오·환경·횟수 제어
RAG Connector
사전 협의 사항
R2 – 협의 없이 즉시 가능
R4 – 타깃 문서 목록 일부 사전 공유 필요
R9 – 문서 업로드 API 별도 제공 필요
공통 – retrieved docs · scores · reranked docs
config.yaml
mode: external · endpoint · auth_token
ExternalRAGConnector
HTTP POST · 의뢰사 RAG 엔드포인트 호출
의뢰사 RAG 시스템 (외부)
블랙박스 · 내부 구조 미공개
응답 + 중간 산출물 반환 (사전 협의 전제)
ResponseParser
응답 포맷 정규화 · 중간 산출물 추출
응답
AttackEvaluator ·
로 전달
중간 로그
AttackEvaluator ·
로 전달
질의 입력(컴포넌트 아님)
CLI - 공격 쿼리 / 일반 질문
SentenceTransformersTextEmbedder
질의 벡터화 : BGE-m3-ko
FAISSEmbeddingRetriever
Clean/Poisoned DB에서 질의 벡터와
유사한 청크 top-k개 찾아옴
SentenceTransformersSimilarityRanker
Re-ranker · bge-reranker-v2-m3-ko · on/off
PromptBuilder
검색 문서(사실 청크) + 질의 결합
Generater
로컬 오픈소스 / GPT-4o-mini / HyperCLOVA X
최종 응답 출력
응답 + 중간 산출물 로그 저장
Attack Evaluator
R2 Evaluator
응답-청크 유사도
R4 Evaluator
b vs b' 일치 여부
R9 Evaluator
트리거 문자열
유출된 정보
공격 성공 시 유출된 정보
한국형 PII 탐지 엔진
Step 1
정규식 탐지
탐지 O & 유효성 검증
자체가 없음 (A-1)
탐지 X
탐지 O
Step 2
체크섬, 구조 검증
유효성 검증 통과 (A-2)
Step 3
NER 기반 탐지
F1 점수 높은 항목 (B-1)
F1 점수 낮은 항목
Step 4
sLLM 교차 검증
교차검증 성공 (B-2)
한국형
PII 확정
ExperimentLogger
실험 전 과정에서
run_id 단위로 로그를 저장
PIIMasker
탐지 PII 마스킹 처리
ReportGenerator
공격 결과·PII 프로파일 등을
담은 pdf 리포트 생성
리포트 출력
CLI · PDF · CSV · JSON